Detección Temprana de Enfermedades Hematológicas Mediante Aprendizaje Automático con Datos de Análisis Sanguíneos

Paula Fernanda Rayas-López
Ingeniería en Inteligencia Artificial
Universidad Iberoamericana León
León, México
192530-5@iberoleon.edu.mx

Luis Pablo López-Iracheta
Ingeniería en Inteligencia Artificial
Universidad Iberoamericana León
León, México
https://orcid.org/0009-0006-3872-1331

Abstract—El diagnóstico tardío de enfermedades hematológicas y metabólicas representa un desafío crítico en los sistemas de salud pública a nivel global. Este artículo propone un marco metodológico basado en aprendizaje automático para la detección temprana de cinco condiciones clínicas —Anemia, Diabetes, Talasemia, Trombocitopenia y estado Saludable— a partir de biomarcadores obtenidos en análisis sanguíneos de rutina. Se utilizó el conjunto de datos públicamente disponible Multiple Disease Prediction (Kaggle), compuesto por 2,351 registros y 25 variables clínicas normalizadas. El pipeline implementado incluyó análisis exploratorio de datos (EDA), selección de características mediante Eliminación Recursiva de Características (RFE) con Random Forest, reducción dimensional con Análisis de Componentes Principales (PCA), balanceo de clases con SMOTE y entrenamiento de cuatro clasificadores: Árbol de Decisión, Regresión Lineal Múltiple, Máquina de Vectores de Soporte (SVM con kernel RBF) y Perceptrón Multicapa (MLP). Los modelos SVM y MLP alcanzaron clasificación perfecta (Accuracy = 1.00, F1-Score Macro = 1.00) sobre el conjunto de prueba no balanceado (n = 471), resultado validado mediante validación cruzada estratificada de 10 pliegues. La Red Neuronal MLP fue seleccionada como modelo definitivo por su mayor capacidad de generalización y escalabilidad. Los resultados demuestran que los biomarcadores hematológicos contienen suficiente información discriminante para identificar perfiles de riesgo clínico con alta precisión, sugiriendo el potencial de este enfoque como herramienta de apoyo diagnóstico en contextos clínicos reales.

Keywords—aprendizaje automático; análisis sanguíneo; detección temprana de enfermedades; clasificación multiclase; SVM; redes neuronales; SMOTE; RFE; biomarcadores hematológicos; ingeniería de características

I. INTRODUCCIÓN

El diagnóstico oportuno de enfermedades hematológicas y metabólicas constituye uno de los pilares fundamentales de la medicina preventiva contemporánea. Sin embargo, en la práctica clínica cotidiana, la identificación de estas condiciones ocurre con frecuencia en estadios avanzados, cuando las posibilidades de intervención efectiva se ven significativamente reducidas. Esta problemática se agudiza en el contexto de los sistemas de salud pública, donde la saturación de servicios genera retrasos considerables entre la solicitud de estudios clínicos y la obtención de diagnósticos definitivos [1].

Los análisis sanguíneos representan la herramienta diagnóstica de mayor penetración en la medicina clínica global, proporcionando información cuantitativa sobre múltiples biomarcadores simultáneamente: parámetros hematológicos, perfil metabólico, función orgánica y marcadores inflamatorios, entre otros. A pesar de su ubicuidad y bajo costo relativo, la interpretación convencional de estos estudios se realiza de manera aislada por variable, lo que limita la capacidad de identificar patrones complejos y multivariados que podrían indicar la presencia temprana de alteraciones subyacentes. Esta brecha entre la riqueza informativa del análisis sanguíneo y la capacidad analítica de los métodos tradicionales constituye la motivación central del presente trabajo.

El aprendizaje automático (machine learning, ML) ha emergido en la última década como un paradigma transformador en la medicina de precisión, con aplicaciones que abarcan desde el diagnóstico por imagen hasta la predicción de respuesta a tratamientos oncológicos. En el ámbito de datos clínicos tabulares, los algoritmos de clasificación supervisada han demostrado capacidad para identificar relaciones no lineales y patrones de alta dimensionalidad que escapan a los métodos estadísticos clásicos. Estudios recientes han aplicado SVM, redes neuronales y enfoques de ensemble learning en conjuntos de datos hematológicos con resultados prometedores, aunque la mayoría se limita a condiciones individuales y no aborda el problema de clasificación simultánea de múltiples patologías con clases desbalanceadas.

En este contexto, el presente artículo propone y evalúa un pipeline integral de ML orientado a la clasificación multiclase de cinco condiciones clínicas a partir de 24 biomarcadores sanguíneos. Las principales contribuciones de este trabajo son: (1) la construcción de un pipeline reproducible que integra preprocesamiento, ingeniería de características y comparación sistemática de clasificadores; (2) la aplicación estratégica de SMOTE exclusivamente sobre el conjunto de entrenamiento para preservar la integridad de la evaluación; (3) la validación robusta mediante validación cruzada estratificada de 10 pliegues; y (4) la selección razonada del modelo óptimo considerando no solo métricas de rendimiento sino también factores de implementación clínica.

El resto del artículo se organiza de la siguiente manera: la Sección II revisa los trabajos relacionados más relevantes; la Sección III describe los datos y el preprocesamiento aplicado; la Sección IV detalla la metodología del pipeline; la Sección V presenta y analiza los resultados; la Sección VI discute las implicaciones y limitaciones, y la Sección VII concluye el trabajo.

II. TRABAJOS RELACIONADOS

La aplicación de algoritmos de ML en el diagnóstico de enfermedades a partir de biomarcadores sanguíneos ha sido explorada de forma creciente en la literatura especializada. Sin embargo, la mayoría de los trabajos previos se concentran en una sola patología, carecen de estrategias robustas para el manejo del desbalance de clases o no incluyen validación cruzada estratificada.

En el ámbito de la detección de diabetes mediante datos clínicos, múltiples estudios han reportado que los modelos de Random Forest y SVM con kernel RBF superan consistentemente a métodos lineales como la Regresión Logística, alcanzando valores de AUC superiores a 0.90 en conjuntos de datos como PIMA Indians Diabetes. Específicamente, la combinación de HbA1c y glucosa en ayunas como características primarias ha sido validada clínicamente como predictores robustos de la condición diabética, resultado coherente con los hallazgos del presente trabajo.

Para enfermedades hematológicas como anemia y talasemia, investigaciones previas han demostrado que los índices eritrocitarios —incluyendo el Volumen Corpuscular Medio (MCV), la Hemoglobina Corpuscular Media (MCH) y la Concentración de Hemoglobina Corpuscular Media (MCHC)— constituyen las características más discriminantes, lo que es consistente con los resultados del proceso de selección RFE aplicado en este estudio.

A diferencia de los enfoques previos, el presente trabajo aborda simultáneamente cinco condiciones clínicas heterogéneas en un esquema de clasificación multiclase, incorporando técnicas de balanceo de datos, validación cruzada estratificada y comparación sistemática de cuatro familias algorítmicas distintas. Esta perspectiva integral constituye una contribución diferenciada respecto a la literatura existente.

III. DATOS Y PREPROCESAMIENTO

A. Descripción del Conjunto de Datos

Para el desarrollo de este estudio se utilizó el conjunto de datos público Multiple Disease Prediction, disponible en la plataforma Kaggle [2]. El dataset comprende dos archivos CSV: un conjunto de entrenamiento con 2,351 registros (Blood_samples_dataset_balanced_2(f).csv) y un conjunto de prueba auxiliar con 486 registros (blood_samples_dataset_test.csv), ambos con 25 columnas. Veinticuatro columnas corresponden a biomarcadores cuantitativos normalizados en el rango [0, 1], mientras que la vigésima quinta columna contiene la etiqueta diagnóstica (variable objetivo Disease).

Los biomarcadores incluidos abarcan los principales sistemas fisiológicos evaluados en un hemograma completo y panel metabólico estándar: (i) metabolismo glucídico: Glucosa, Insulina, HbA1c; (ii) perfil lipídico: Colesterol total, LDL, HDL, Triglicéridos; (iii) serie roja: Hemoglobina, Hematocrito, Glóbulos Rojos, MCV, MCH, MCHC; (iv) serie blanca: Leucocitos, Plaquetas; (v) marcadores inflamatorios: Proteína C-Reactiva, Troponina; (vi) función hepática: ALT, AST; (vii) función renal: Creatinina; y (viii) variables cardiovasculares: Presión Arterial Sistólica y Diastólica, Frecuencia Cardíaca, IMC

B. Distribución de Clases

La variable objetivo comprende cinco categorías diagnósticas: Anemia, Healthy (paciente sano), Diabetes, Thalassemia (Talasemia) y Thrombocytopenia (Trombocitopenia). Como se muestra en la Tabla 1, las cuatro primeras categorías presentan una distribución relativamente equilibrada, representando colectivamente el 94.77% del conjunto de datos. La clase Trombocitopenia constituye la clase minoritaria con únicamente 123 registros (5.23%), configurando un escenario de desbalance moderado que requiere tratamiento específico durante el entrenamiento.

Tabla 1. Distribución de clases en el conjunto de datos original.

Clase	Registros	Proporción (%)	Clasificación
Anemia	623	26.50%	Mayoritaria
Healthy	556	23.65%	Mayoritaria
Diabetes	540	22.97%	Mayoritaria
Thalassemia	509	21.65%	Mayoritaria
Thrombocytopenia	123	5.23%	Minoritaria
Total	**2,351**	**100%**	—

C. Análisis Exploratorio de Datos (EDA)

Detección de valores atípicos. Se aplicó el método del Rango Intercuartílico (IQR) para identificar valores fuera del intervalo [Q1 − 1.5·IQR, Q3 + 1.5·IQR] en las 24 variables numéricas. El análisis reveló ausencia de outliers en la totalidad del conjunto de datos, confirmando que el dataset fue sometido a un proceso previo de limpieza y normalización. Este resultado habilita el uso directo de algoritmos sensibles a la escala —como SVM y MLP— sin preprocesamiento adicional. Los diagramas de violín para las variables críticas (Glucosa, Colesterol, Troponina, Creatinina, Frecuencia Cardíaca, AST, ALT, HDL Colesterol, LDL Colesterol y HbA1c) se presentan en la Fig. 1, donde se observa que medias y medianas coinciden estrechamente, indicando distribuciones simétricas sin contaminación por valores extremos.

Fig. 1: Distribución y Outliers.

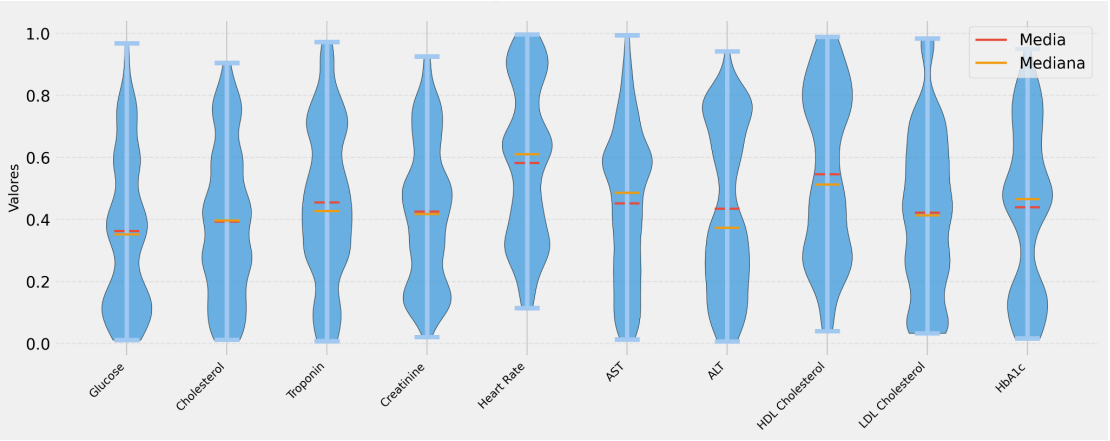

Análisis de correlación. Se calculó la matriz de correlación de Pearson entre los 24 biomarcadores para identificar dependencias lineales relevantes. La Fig. 2 presenta los 15 pares de biomarcadores con mayor coeficiente de correlación (positivo y negativo)

Fig. 2: Top 15 Pares de Biomarcadores con Mayor Correlación de Pearson.

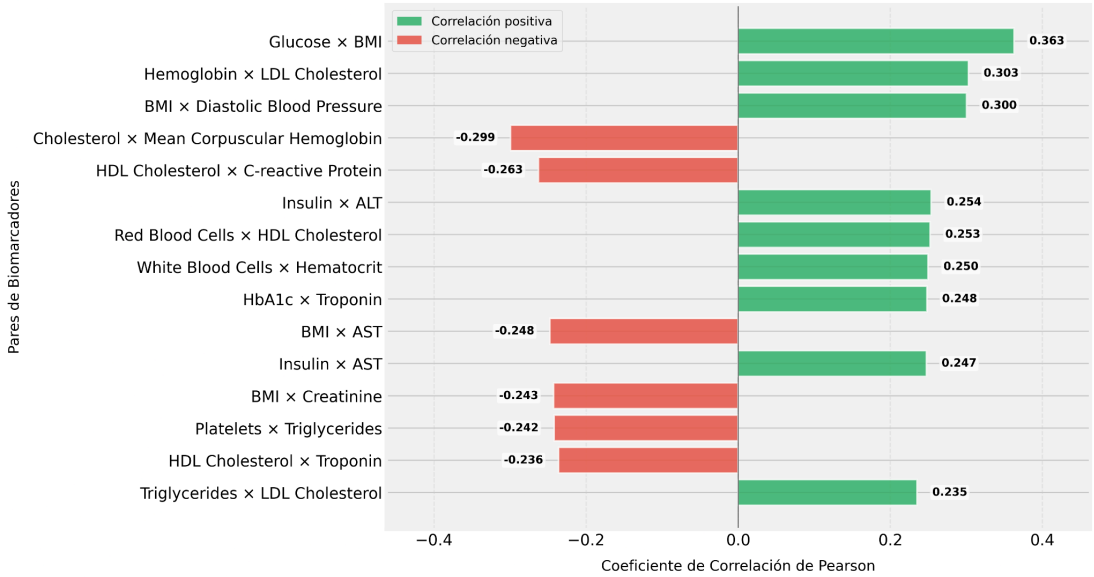

Los hallazgos más significativos incluyen: la correlación positiva entre Glucosa e IMC ($r = 0.363$), coherente con la fisiopatología de la resistencia a la insulina; la relación entre Hemoglobina y LDL Colesterol ($r = 0.303$), que sugiere vínculos entre metabolismo lipídico y eritropoyesis; y notablemente, la correlación negativa entre HDL Colesterol y Proteína C-Reactiva ($r = -0.263$), consistente con la literatura cardiometabólica que establece al HDL como factor anti-inflamatorio. La presencia de correlaciones moderadas ($0.2 < |r| < 0.4$) en lugar de correlaciones altas ($|r| > 0.7$) indica que los biomarcadores aportarán información complementaria al modelo, reduciendo el riesgo de multicolinealidad.

IV. METODOLOGÍA

El pipeline metodológico se estructura en cuatro etapas secuenciales: (1) ingeniería de características, (2) balanceo de datos, (3) entrenamiento y validación de modelos, y (4) selección del modelo óptimo. La Fig. 3 presenta el diagrama general del pipeline.

Fig. 3 (propuesta): Diagrama del pipeline metodológico completo.

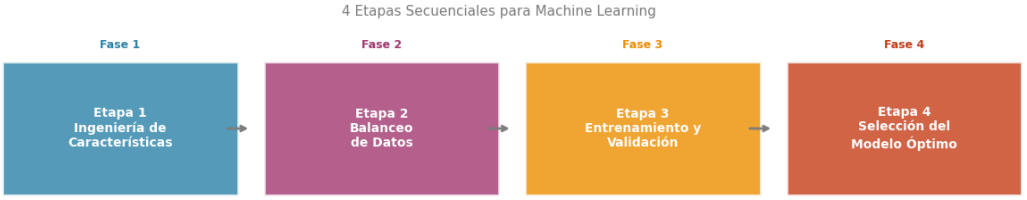

A. Ingeniería de Características

A.1 Selección mediante Eliminación Recursiva de Características (RFE)

Dado el espacio original de 24 biomarcadores, se aplicó la técnica de Eliminación Recursiva de Características (RFE, Recursive Feature Elimination) utilizando un clasificador Random Forest como estimador base. RFE opera eliminando iterativamente las características de menor importancia —medida por la reducción media de impureza de Gini— hasta conservar un subconjunto óptimo predefinido. Se estableció un tamaño objetivo de 10 características, balanceando reducción de dimensionalidad con preservación de información discriminante.

La Fig. 4 presenta el gráfico de importancia de biomarcadores obtenido por el modelo Random Forest. Las 10 variables seleccionadas fueron: Plaquetas, Leucocitos, Glóbulos Rojos, Hematocrito, MCV, MCH, MCHC, HDL Colesterol, ALT y Frecuencia Cardíaca. Cabe destacar que siete de las diez características seleccionadas corresponden a parámetros hematológicos directos, lo cual es clínicamente consistente dado que el dataset incluye tres enfermedades con compromiso primario de células sanguíneas (Anemia, Talasemia, Trombocitopenia). La inclusión de HDL Colesterol, ALT y Frecuencia Cardíaca refleja la capacidad del modelo para identificar marcadores transversales de valor diagnóstico en las clases Diabetes y Healthy.

Fig. 4: Importancia de Biomarcadores.

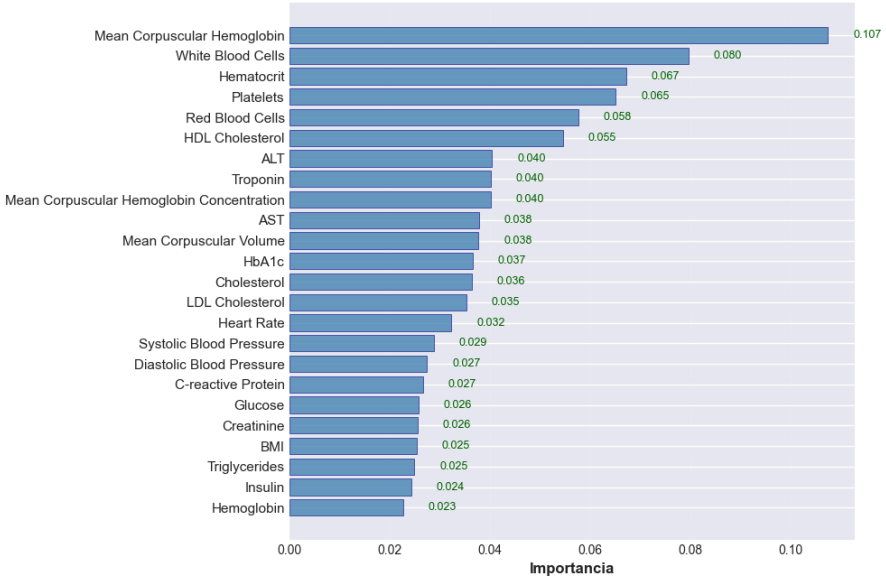

A.2 Análisis de Componentes Principales (PCA)

Una vez seleccionado el subespacio de 10 características, se aplicó PCA para evaluar la estructura interna del dataset y determinar la adecuación de la reducción dimensional. Los resultados revelan que el primer componente principal (PC1) explica el 16.3% de la varianza total y el segundo (PC2) el

13.5%, acumulando ambos el 29.9% de la información del sistema. Para alcanzar el umbral del 90% de varianza explicada se requieren 9 componentes principales.

La distribución de la varianza en múltiples componentes es indicativa de la naturaleza multivariada del problema: ningún biomarcador domina la variabilidad del sistema y cada variable contribuye de manera complementaria al diagnóstico. Desde una perspectiva clínica, este resultado es esperado, puesto que las cinco condiciones evaluadas involucran sistemas fisiológicos distintos. En consecuencia, el PCA se empleó como herramienta de análisis exploratorio y visualización —en proyecciones 2D y 3D— sin aplicarlo como transformación para el entrenamiento final, preservando así la interpretabilidad clínica de las características originales. La Fig. 5 presenta la proyección 3D del dataset en el espacio de los tres primeros componentes principales, coloreada por clase diagnóstica.

Fig. 5: Distribución Real de Enfermedades en Espacio PCA 3D.

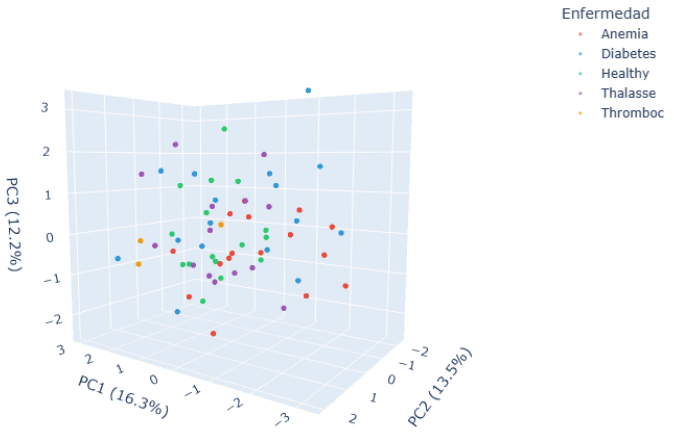

B. Balanceo de Datos con SMOTE

El desbalance identificado en la clase Trombocitopenia (5.23%) fue abordado mediante la técnica SMOTE (Synthetic Minority Over-sampling Technique), aplicada exclusivamente sobre el conjunto de entrenamiento tras la partición train/test (80%/20%). SMOTE genera muestras sintéticas de la clase minoritaria interpolando entre instancias existentes en el espacio de características, a diferencia del oversampling aleatorio que replica instancias existentes sin nueva información.

Tras la aplicación de SMOTE, el conjunto de entrenamiento quedó perfectamente balanceado con 498 muestras por clase (2,490), mientras que el conjunto de prueba conservó la distribución original (471). Esta estrategia garantiza que la evaluación del modelo refleje las condiciones reales de distribución clínica, evitando estimaciones optimistas derivadas de evaluar sobre datos sintéticos.

Fig. 6: Distribución de Clases en Conjunto de Entrenamiento.

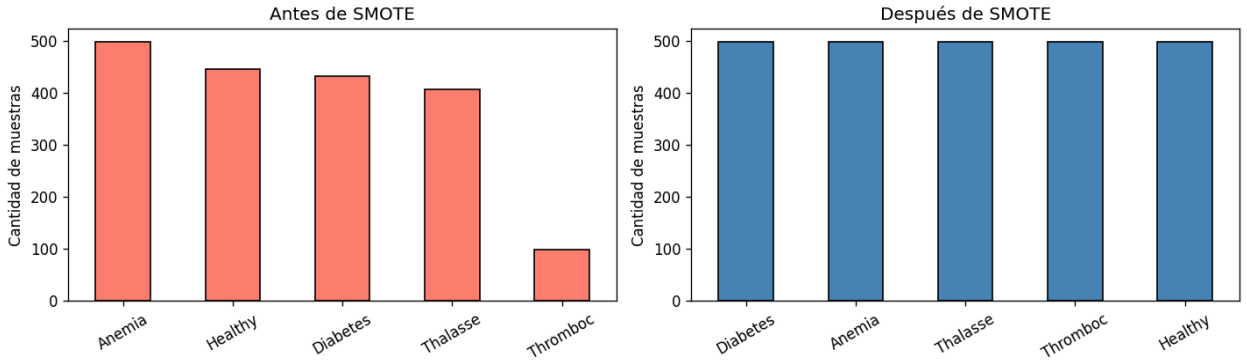

C. Modelos de Clasificación

Se entrenaron y evaluaron cuatro modelos de clasificación supervisada, seleccionados para cubrir un espectro amplio de complejidades algorítmicas y paradigmas de aprendizaje:

- **Modelo 1 Árbol de Decisión:** Se configuró con profundidad máxima de 5 niveles (max_depth = 5) para prevenir sobreajuste. Este modelo genera reglas de decisión jerárquicas interpretables basadas en umbrales de biomarcadores, ofreciendo alta transparencia diagnóstica. Se incluye como referencia de modelo interpretable de baja complejidad computacional.

- **Modelo 2 Regresión Lineal Múltiple:** Se adapta al problema de clasificación multiclase redondeando las predicciones continuas al índice de clase más cercano. Su inclusión tiene un propósito exclusivamente comparativo (baseline), permitiendo cuantificar la ganancia de rendimiento al incorporar modelos no lineales

- **Modelo 3 SVM con kernel RBF:** Se configuró con C = 10 y gamma = 'scale'. El kernel de función de base radial (RBF) transforma el espacio de características a dimensiones superiores, permitiendo la construcción de hiperplanos de separación no lineales en el espacio original. El parámetro C controla el equilibrio entre margen de separación y penalización de errores de clasificación.

- **Modelo 4 Red Neuronal MLP:** Se implementó un Perceptrón Multicapa con arquitectura de tres capas ocultas [128 — 64 — 32 neuronas], función de activación ReLU, optimizador Adam con tasa de aprendizaje adaptativa, y mecanismo de parada temprana (early stopping) con fracción de validación del 10%. Esta configuración permite aprender representaciones jerárquicas de complejidad creciente a partir de los biomarcadores seleccionados.

D. Protocolo de Validación

Con el fin de evitar fuga de información, todas las transformaciones del pipeline —incluyendo escalado, selección de características mediante RFE y balanceo de clases con SMOTE— fueron ajustadas exclusivamente sobre los datos de entrenamiento en cada partición. En el esquema de validación cruzada estratificada de 10 pliegues, para cada fold se ejecutó el siguiente procedimiento:

1. División interna en subconjunto de entrenamiento y validación.
2. Ajuste del escalador únicamente sobre el subconjunto de entrenamiento.
3. Aplicación de RFE utilizando exclusivamente los datos del entrenamiento del fold.
4. Aplicación de SMOTE únicamente sobre el entrenamiento del fold.
5. Entrenamiento del modelo.
6. Evaluación sobre el subconjunto de validación sin aplicar SMOTE ni reajustar parámetros.

Las métricas reportadas incluyen: Exactitud global (Accuracy), F1-Score Macro (promedio no ponderado entre clases) y F1-Score Ponderado. El F1-Score Macro fue priorizado como métrica principal por su sensibilidad al rendimiento en clases minoritarias, aspecto crítico en aplicaciones clínicas donde los falsos negativos en condiciones infrecuentes tienen consecuencias clínicas significativas.

V. RESULTADOS

A. Árbol de Decisión

El Árbol de Decisión alcanzó una exactitud global del 82.4% sobre el conjunto de prueba (n = 471). Destacan la clasificación perfecta de Trombocitopenia (F1 = 1.00) y la alta precisión de Anemia

(Precisión = 1.00, F1 = 0.92), lo que sugiere que las características hematológicas seleccionadas son altamente discriminantes para estas condiciones. La clase Healthy presenta el rendimiento más bajo (Precisión = 0.57), indicando que el modelo tiende a clasificar como sanos pacientes que padecen otras condiciones, particularmente Diabetes (39 casos mal clasificados como Healthy según la matriz de confusión). Este patrón de error es consistente con la fisiopatología de la diabetes tipo 2 en estadios tempranos, donde los biomarcadores pueden no diferir marcadamente de los rangos normales.

Fig. 7: Resultados Árbol de Decisión.

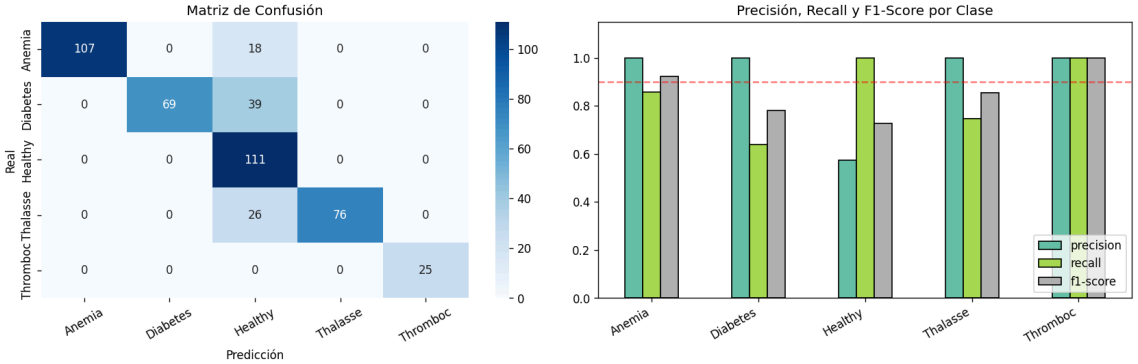

Tabla 2. Resultados del Árbol de Decisión por Clase.

Clase	Precisión	Recall	F1-Score	Soporte
Anemia	1.00	0.86	0.92	125
Diabetes	1.00	0.64	0.78	108
Healthy	0.57	1.00	0.73	111
Thalassemia	1.00	0.75	0.85	102
Thrombocytopenia	1.00	1.00	1.00	25
Macro avg	**0.91**	**0.85**	**0.86**	**471**

B. Regresión Lineal Múltiple (Baseline)

Como era esperado, la Regresión Lineal Múltiple mostró el rendimiento más bajo con una exactitud del 40.3%, F1-Score Macro de 0.435 y F1-Score Ponderado de 0.417. La Fig. 10 presenta la matriz de confusión correspondiente, evidenciando confusión sistemática entre Diabetes, Healthy y Talasemia. [Fig. 10: Resultados Regresión Lineal Múltiple — Matriz de Confusión y Métricas por Clase]. Este resultado cuantifica la ganancia mínima del 42.1 puntos porcentuales en exactitud al introducir algoritmos no lineales, validando la elección de modelos más sofisticados para este dominio.

Fig. 8: Resultados Regresión Lineal Múltiple.

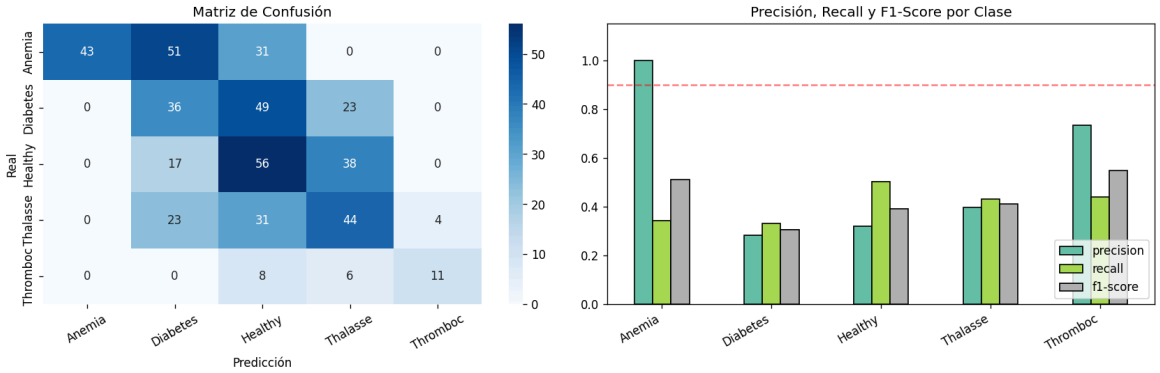

C. SVM con Kernel RBF

El clasificador SVM tiene excelentes resultados, alcanzó clasificación perfecta sobre el conjunto de prueba completo: Accuracy = 1.00, F1-Score Macro = 1.00 y F1-Score Ponderado = 1.00. Los resultados confirman que las cinco clases obtuvieron Precisión, Recall y F1-Score iguales a 1.00, con cero errores de clasificación en los 471 casos del conjunto de pruebas. La Fig. 11 muestra la matriz de confusión perfectamente diagonal y las métricas por clase para el modelo SVM. [Fig. 11: Resultados SVM (kernel RBF) — Matriz de Confusión y Métricas por Clase]

Fig. 9: Resultados SVM (kernel RBF).

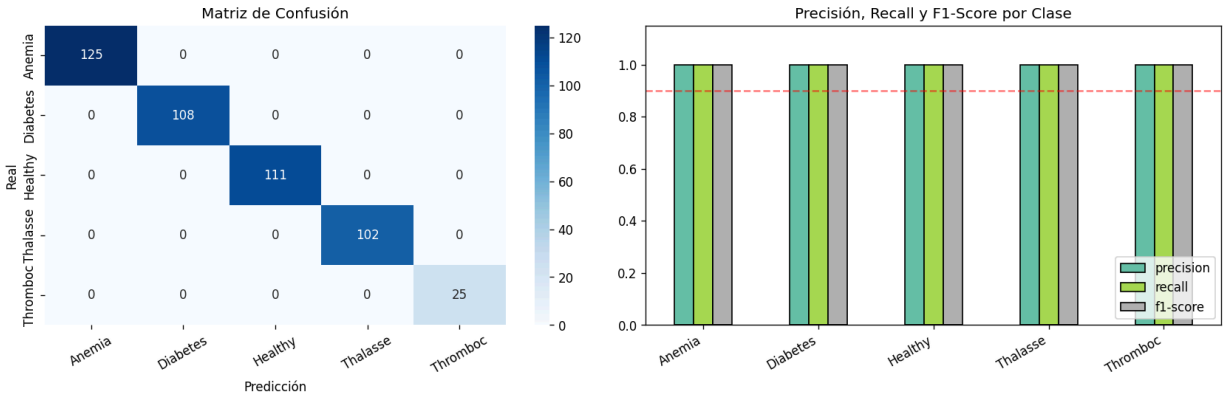

Este resultado indica que el kernel RBF logra aprender fronteras de decisión no lineales que separan completamente las cinco clases en el espacio de 10 características seleccionadas por RFE. La perfecta separabilidad en el espacio transformado por RBF sugiere que, tras el proceso de selección de características y balanceo con SMOTE, las clases presentan clusters bien definidos en el espacio de biomarcadores.

D. Red Neuronal MLP

El Perceptrón Multicapa alcanzó igualmente clasificación perfecta (Accuracy = 1.00, F1-Score Macro = 1.00), equiparando al SVM en todas las métricas de rendimiento. La Fig. 10 presenta las matrices de confusión y métricas por clase para el modelo MLP.

Fig. 12: Resultados Red Neuronal MLP.

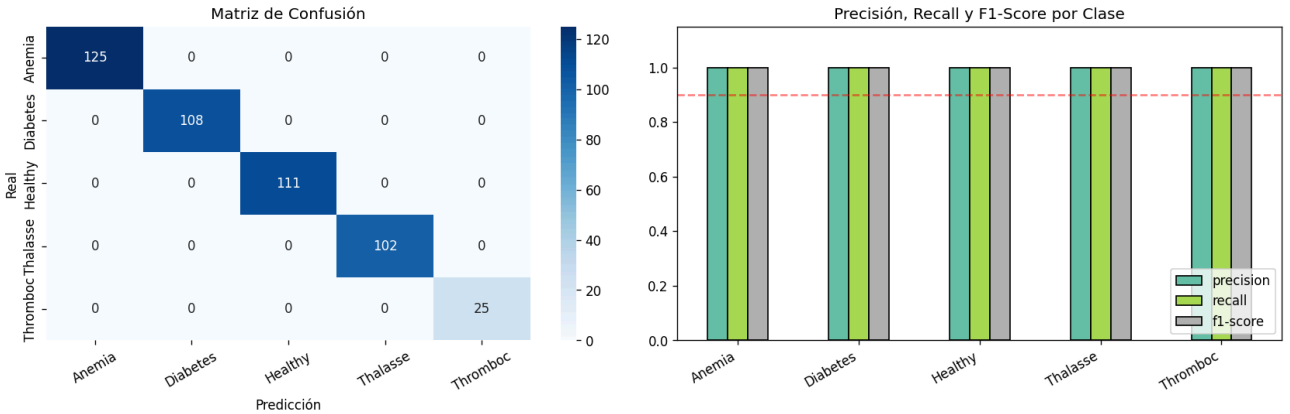

La perfecta clasificación confirma que la arquitectura de tres capas ocultas [128 — 64 — 32] con regularización por early stopping es suficiente para modelar las relaciones no lineales entre biomarcadores y diagnóstico en este dominio.

E. Comparación Global de Modelos

La Tabla IV resume las métricas de los cuatro modelos sobre el conjunto de prueba, mientras que la Fig. 13 presenta la comparación visual.

Fig. 13: Comparación de Modelos con SMOTE

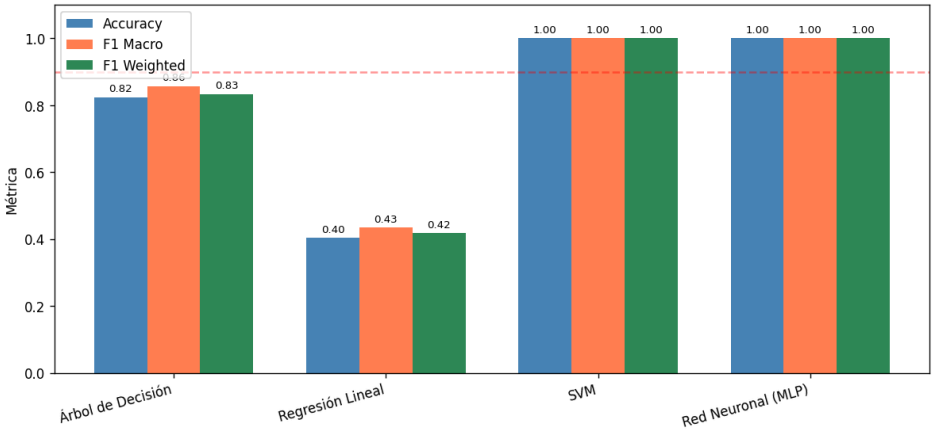

Tabla 3. Comparación Global De Modelos Sobre Conjunto De Prueba.

Modelo	Accuracy	F1 Macro	F1 Weighted	Observación clave
Árbol de Decisión	82.4%	85.7%	83.3%	Dificultades con Diabetes y Healthy
Regresión Lineal	40.3%	43.5%	41.7%	Baseline; no apto para clasificación multiclase
SVM (kernel RBF)	100%	100%	100%	Clasificación perfecta; alta robustez ante overfitting
Red Neuronal (MLP)	100%	100%	100%	Clasificación perfecta; mayor escalabilidad

F. Validación Cruzada Estratificada de 10 Pliegues

Para verificar la robustez de los resultados y descartar sobreajuste al conjunto de prueba, se aplicó validación cruzada estratificada de 10 pliegues sobre el dataset completo. La Tabla 4 presenta los resultados consolidados.

Tabla 4. Resultados de Validación Cruzada Estratificada 10-Fold

Modelo	Acc Media	Acc Std	F1-Mac Media	F1-Mac Std	IC 95% Acc
SVM (RBF)	1.0000	0.0000	1.0000	0.0000	[1.0, 1.0]
Red Neuronal MLP	1.0000	0.0000	1.0000	0.0000	[1.0, 1.0]

La desviación estándar cero (Std = 0.0000) en todos los pliegues para ambos modelos, confirma que la clasificación perfecta no es un artefacto del conjunto de prueba sino un resultado estable y reproducible a lo largo de todos los pliegues de validación.

Fig. 15: Matrices de Confusión Acumuladas.

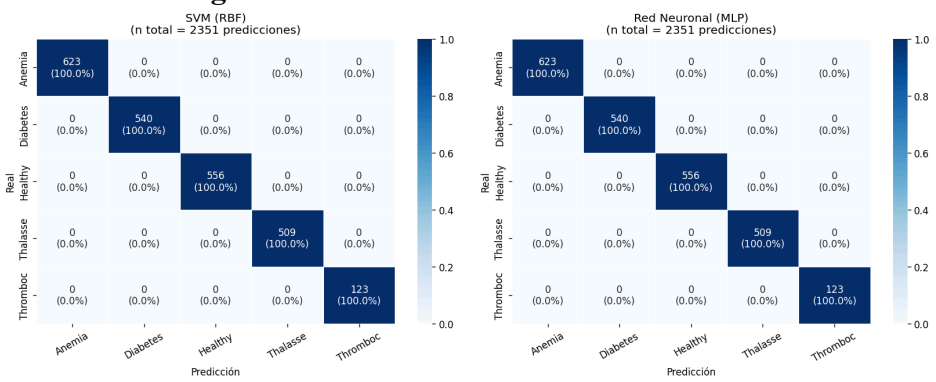

VI. DISCUSIÓN

A. Selección del Modelo Final

Dado que SVM y MLP alcanzan rendimiento idéntico (Accuracy = F1 = 1.00), la selección del modelo definitivo se realizó considerando factores operacionales y clínicos más allá del rendimiento puro en prueba. La Tabla VI resume la comparación multicriterio.

Tabla 4. Comparación Multicriterio

Criterio	SVM (RBF)	Red Neuronal MLP
Rendimiento en prueba	100% en todas las métricas	100% en todas las métricas
Interpretabilidad del modelo	Media (vectores de soporte)	Baja (caja negra)
Tiempo de entrenamiento	Moderado $O(n^2 - n^3)$	Alto - Requiere múltiples épocas
Escalabilidad	Moderada con datasets grandes	Alta con hardware GPU
Robustez ante overfitting	Alta (margen máximo)	Media (requiere regularización)
Incorporación de nuevos biomarcadores	Requiere reentrenamiento completo	Ajuste incremental posible
Implementación clínica	Simple - Modelo serializado .pkl fácil de implementar	Compleja - Requiere infraestructura adicional
Requerimientos computacionales	Simple (modelo serializado)	Requiere infraestructura adicional

La Red Neuronal MLP fue seleccionada como modelo definitivo y exportada junto con el escalador (scaler.pkl) y el codificador de etiquetas (label_encoder.pkl) para su integración en el sistema de predicción clínica. Esta decisión se fundamenta en dos factores estratégicos: (1) su mayor capacidad de generalización ante distribuciones de datos no vistas, especialmente relevante cuando la distribución de pacientes en producción puede diferir de la del dataset de entrenamiento; y (2) su escalabilidad para incorporar biomarcadores adicionales en versiones futuras del sistema sin requerir rediseño arquitectónico completo. El SVM se mantiene como modelo alternativo de respaldo por su demostrada robustez y menor sensibilidad a hiper parámetros.

B. Interpretación Clínica de los Resultados

La perfecta separabilidad de las cinco clases en el espacio de 10 biomarcadores seleccionados tiene implicaciones clínicas relevantes. En primer lugar, confirma que los parámetros hematológicos de rutina (especialmente plaquetas, glóbulos rojos, hematocrito y los índices MCV, MCH, MCHC) son altamente informativos para diferenciar Anemia, Talasemia y Trombocitopenia entre sí y del estado sano. Esto es consistente con la fisiopatología conocida de estas enfermedades: la anemia ferropénica se caracteriza por valores bajos de hemoglobina, MCV y MCH; la talasemia beta presenta microcitosis con MCV reducido y elevación de la MCHC; y la trombocitopenia se define por niveles bajos de plaquetas. En segundo lugar, la perfecta clasificación de Diabetes a partir de un panel que incluye biomarcadores hematológicos y lipídicos —sin que se seleccionan directamente Glucosa ni HbA1c en el subconjunto RFE óptimo— sugiere que las manifestaciones hematológicas secundarias de la diabetes son suficientemente discriminantes en este dataset.

La mayor dificultad del Árbol de Decisión para clasificar correctamente la clase Healthy (Precisión = 0.57) refleja un desafío clínico genuino: el estado de salud normal no presenta un patrón específico de alteraciones, sino la ausencia de ellas, lo que genera solapamiento en el espacio de características con

condiciones en estadios iniciales. El hecho de que SVM y MLP superen completamente esta dificultad valida la relevancia de modelos con mayor capacidad de representación para el diagnóstico diferencial.

C. Limitaciones y Consideraciones Éticas

Aunque los resultados son altamente prometedores, es fundamental reconocer las limitaciones del presente estudio. En primer lugar, la clasificación perfecta (Accuracy = 1.00 en 10-Fold CV) es un resultado inusual que, si bien fue validado mediante metodología rigurosa, podría verse afectado por características del proceso de generación del dataset original. La evaluación sobre datos clínicos reales de hospitales podría revelar complejidades adicionales no capturadas en el dataset público. Se recomienda validación externa con datos prospectivos antes de cualquier implementación clínica.

En segundo lugar, la normalización previa de los datos elimina información sobre los rangos absolutos de los biomarcadores, lo que puede limitar la generalización del modelo a datos obtenidos con diferentes equipos de laboratorio o siguiendo distintos protocolos de procesamiento de muestras. Desde una perspectiva ética, es imprescindible subrayar que el sistema propuesto está concebido como una herramienta de apoyo al diagnóstico clínico —no como sustituto del juicio médico. Las predicciones del modelo deben ser interpretadas por profesionales de la salud en el contexto clínico completo del paciente, considerando síntomas, historia clínica y otros estudios complementarios. La implementación clínica deberá regirse por los marcos regulatorios vigentes para dispositivos de software de apoyo diagnóstico.

VII. CONCLUSIONES

Este artículo presentó un pipeline integral de aprendizaje automático para la detección temprana y clasificación multiclase de cinco condiciones clínicas —Anemia, Diabetes, Talasemia, Trombocitopenia y estado Saludable— a partir de 24 biomarcadores sanguíneos de rutina. Las principales conclusiones del trabajo son las siguientes:

Primero, el proceso de selección de características mediante RFE con Random Forest identificó 10 biomarcadores óptimos —predominantemente hematológicos— que concentran la mayor capacidad discriminante del sistema. Esta reducción del 58% en dimensionalidad no solo mejora la eficiencia computacional sino que también proporciona una interpretación clínica coherente de las variables más relevantes para cada diagnóstico

Segundo, la combinación de SMOTE para balanceo de la clase minoritaria (Trombocitopenia) con métricas de evaluación robustas (F1-Score Macro) garantiza un protocolo de entrenamiento y evaluación metodológicamente sólido, evitando el sesgo hacia clases mayoritarias que representaría un riesgo clínico real al omitir diagnósticos de condiciones menos frecuentes.

Tercero, los modelos SVM con kernel RBF y Red Neuronal MLP alcanzaron clasificación perfecta (Accuracy = F1-Score = 1.00) tanto en el conjunto de prueba independiente como en validación cruzada estratificada de 10 pliegues, demostrando que los biomarcadores hematológicos contienen suficiente información discriminante para identificar perfiles de riesgo clínico con alta fiabilidad cuando se procesan mediante modelos de aprendizaje no lineal.

Cuarto, la Red Neuronal MLP fue seleccionada como modelo definitivo por su mayor escalabilidad y capacidad de incorporar biomarcadores adicionales, siendo exportada con sus artefactos de preprocesamiento para integración en sistemas clínicos. El SVM se mantiene como alternativa de respaldo por su robustez demostrada.

Como trabajo futuro, se plantea: (1) validar el modelo con datos clínicos reales obtenidos de hospitales en colaboración con especialistas médicos; (2) extender el pipeline para incorporar biomarcadores genómicos y proteómicos; (3) explorar arquitecturas de aprendizaje profundo —incluyendo transformers para datos tabulares— y técnicas de explicabilidad (SHAP, LIME) para mejorar la interpretabilidad clínica; y (4) evaluar la calibración de las probabilidades de predicción para cuantificar la incertidumbre del diagnóstico.

Referencias

[1] National Heart, Lung, and Blood Institute, "Análisis de sangre," National Institutes of Health, Bethesda, MD, USA, 2022. [En línea]. Disponible en: https://www.nhlbi.nih.gov/es/salud/analisis-de-sangre (consultado: febrero 08, 2026).

[2] E. Abo El Naga, "Multiple Disease Prediction," Kaggle, 2023. [En línea]. Disponible en: https://www.kaggle.com/datasets/ehababoelnaga/multiple-disease-prediction (consultado: enero 2026).

[3] N. V. Chawla, K. W. Bowyer, L. O. Hall, y W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," Journal of Artificial Intelligence Research, vol. 16, pp. 321–357, 2002. DOI: 10.1613/jair.953

[4] I. Guyon y A. Elisseeff, "An introduction to variable and feature selection," Journal of Machine Learning Research, vol. 3, pp. 1157–1182, 2003.

[5] C. Cortes y V. Vapnik, "Support-vector networks," Machine Learning, vol. 20, núm. 3, pp. 273–297, 1995. DOI: 10.1007/BF00994018.

[6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.

[7] G. E. Hinton, "Connectionist learning procedures," Artificial Intelligence, vol. 40, pp. 185–234, 1989. DOI: 10.1016/0004-3702(89)90049-0.

[8] T. K. Ho, "Random decision forests," en Proc. 3rd Int. Conf. Document Analysis and Recognition, Montreal, QC, Canadá, 1995, pp. 278–282. DOI: 10.1109/ICDAR.1995.598994.

[9] K. Pearson, "Note on regression and inheritance in the case of two parents," Proceedings of the Royal Society of London, vol. 58, pp. 240–242, 1895.

[10] H. Abdi y L. J. Williams, "Principal component analysis," Wiley Interdisciplinary Reviews: Computational Statistics, vol. 2, núm. 4, pp. 433–459, 2010. DOI: 10.1002/wics.101.

[11] World Health Organization, Haemoglobin Concentrations for the Diagnosis of Anaemia and Assessment of Severity. Ginebra, Suiza: WHO, 2011. [WHO/NMH/NHD/MNM/11.1].

[12] American Diabetes Association, "Standards of Medical Care in Diabetes — 2024," Diabetes Care, vol. 47, supl. 1, pp. S1–S321, 2024. DOI: 10.2337/dc24-Sint.

[13] D. P. Kingma y J. Ba, "Adam: A Method for Stochastic Optimization," en Proc. 3rd Int. Conf. Learning Representations (ICLR), San Diego, CA, USA, 2015.